

宋子宸

手机：(+86) 18893826281 · 邮箱：songzch21@lzu.edu.cn

性别：男 · 籍贯：安徽省淮北市

教育背景

兰州大学 (985), 计算机科学与技术, 学士	2021.09 - 2025.06
成均馆大学 (QS 123), 应用人工智能, 全职研究助理	2025.09 - 2026.06
香港城市大学 (QS 63), 计算机科学, 硕士	2026.09 - 2028.06

实习经历

人工智能与数字经济广东省实验室 (深圳), 科研实习生	2024
• 单位: 人工智能与数字经济广东省实验室 (深圳)	
• 经历: 跟随舒瑶研究员研究大语言模型的优化和安全隐私攻击, 并且完成一篇论文投在 AAAI 2026	
成均馆大学 (首尔), 全职科研助理	2025
• 单位: 成均馆大学 (首尔)	
• 经历: 跟随 Tamer Abuhmed 教授研究大语言模型的优化和安全隐私攻击, 并且完成一篇论文投在 EACL 2026	
大湾区昇腾算力应用创新研究院 (深圳), 科研实习生	2026
• 单位: 大湾区昇腾算力应用创新研究院 (深圳)	
• 经历: 跟随许飞研究员研究大语言模型的优化和安全隐私攻击, 并且完成一篇论文投在 IJCAI 2026	

已发表论文

Optimization and Robustness-Informed Membership Inference Attacks for LLMs,	2025
• AAAI 2026 Main track (CCF A)	
• 宋子宸, 张启新, 李明, 舒瑶	
UAM-MARL: Uncertainty-Aware Modality-Enhanced Multi-Agent Reinforcement Learning with LLM-Guided Graph Policies,	2025
• AAMAS 2026 Main Track Full (CORE A*)	
• 宋子宸, 李维佳	
RoZO: Geometry-Aware Zeroth-Order Fine-Tuning on Low-Rank Adapters for Black-Box Large Language Models,	2025
• EACL 2026 Main(CORE A)	
• 宋子宸, 李维佳	
GI-MIA: The Group-Invariant Membership Inference Attacks Against the Large Language Models,	2025
• ARR October 2025	
• 宋子宸, Farman Ali, Tamer Abuhmed	
When Comments Aren't What They Seem: The Social Media Comment Toxicity Detector for Understanding Contextual Comments,	2025
• ESWA (中科院一区)	
• 宋子宸, 樊晓鹏, 王宇桐, 闫菲璇, 吴子衿, 康仲锋	
Compositional Concept Extraction with Multimodal Large Models: A Unified Framework with Thought Chain Optimization,	2025
• ESWA (中科院一区)	
• 吴雨欣 (共同一作), 宋子宸 (共同一作), 黄思谭, 康仲锋	

A new perspective on the performance and hallucinations of large language models: Layer Activation Distribution,	2025
• ARR October 2025 • 宋子宸, 黄思谭, 吴雨欣, 康仲锋	
Mamba-MSCCA-Net: Efficient change detection for remote sensing images,	2025
• Displays (中科院二区) • 宋子宸, 吴雨鑫, 黄思谭	
Pulse transfer learning: multi-area river ammonia nitrogen prediction with limited data,	2024
• Expert Systems With Applications (中科院一区 IF 7.5) • 宋子宸, 聂伯颖, 黄思谭	
EM-MIAs: Enhancing Membership Inference Attacks in Large Language Models through Ensemble Modeling,	2025
• ICASSP 2025 (CCF-B) • 宋子宸, 黄思谭, 康仲锋	
Mamba-CCA: AnEfficient Framework for EEG Emotion Recognition,	2025
• Cogsci (CCF B) • 宋子宸, 吴雨鑫	
SAMM: A Selective Attention Sequential Model for EEG-EOG Vigilance Estimation,	2025
• Cogsci (CCF B) • 宋子宸, 仝雨希, 吴雨鑫	
Mutual Information Dropout: Mutual Information Can Be All You Need,	2023
• ICANN 2023 (CCF C) • 宋子宸, 马闪	

研究与服务

研究领域,

- 安全：成员推断攻击（MIAs）、大语言模型的数据窃取攻击
- 隐私保护：训练数据隐私泄露、模型反推与隐私防御
- 大语言模型：多模态大语言模型优化、指令对齐与高效微调
- 多模态学习：视觉-语言模型（VLMs）、跨模态表示学习
- 开放世界学习：开放世界识别、持续学习与分布外泛化
- 多智能体系统：开放世界多智能体系统、基于 LLM 的协作与博弈
- 模型安全评估：LLM 鲁棒性评测、对抗样本与红队测试

社团及服务,

- 科研助理：光明实验室、悉尼科技大学
- 审稿人：Applied Artificial Intelligence, WWW 2025, TGRS, ESWA, AISTATS

合作者,

- 舒瑶, 许飞, 王伟（光明实验室）
- 李维佳, 吴雨欣, 黄思谭, 聂伯颖, 康仲锋（兰州大学）
- 汪守金（悉尼科技大学 UTS）
- Tamer Abuhmed, Farman Ali（SKKU 成均馆大学）
- 仝雨希（中央财经大学）